

Modular DP: guía simple de los experimentos

Aprendizaje, demanda y elección de calidad

Reporte basado en el perfil numérico full

24 de julio de 2026

Resumen

Este reporte explica, con palabras y notación sencillas, los experimentos de **Modular DP**. El objetivo es entender cómo distintas reglas de aprendizaje cambian la demanda del vendedor A y, con ello, su incentivo para usar un producto costoso pero de mayor calidad. Primero se presenta el modelo común; después se describen Thompson sampling, actualizaciones escaladas, temperatura, epsilon-greedy y olvido. Finalmente se resumen el programa dinámico, las simulaciones, los principales resultados y sus limitaciones.

Índice

1. La pregunta económica	3
2. Creencias y demanda	3
2.1. La creencia básica	3
2.2. Thompson sampling estándar	4
3. Métodos comparados	4
3.1. Actualizaciones escaladas	4
3.2. Temperatura que preserva la media	4
3.3. Epsilon-greedy uniforme	5
3.4. Olvido	5
4. El problema dinámico del vendedor	5
5. Qué experimentos se realizaron	6
5.1. Sensibilidad de la demanda	6
5.2. Regiones de política	7
5.3. Simulaciones largas	8

5.4. Matriz dinámica para distintos valores de p_0	9
6. Cómo se resolvió numéricamente	10
6.1. Estados discretos	10
6.2. Estados continuos de olvido	10
6.3. Validaciones	11
7. Lectura simple de los resultados	11
7.1. Métodos de conteos acumulados	11
7.2. Epsilon-greedy	12
7.3. Olvido	12
8. Qué no debe concluirse	12
9. Conclusión	13

1. La pregunta económica

Hay dos vendedores. El vendedor B ofrece una calidad conocida, denotada por p_0 . El vendedor A tiene una reputación que los usuarios aprenden a partir de resultados binarios: éxito o fracaso.

Cuando A recibe una interacción, elige en privado entre dos productos:

Producto	Probabilidad de éxito	Costo	Ganancia inmediata
1: barato	$p_1 = 0.35$	$c_1 = 0.05$	$R - c_1 = 0.95$
2: alta calidad	$p_2 = 0.80$	$c_2 = 0.65$	$R - c_2 = 0.35$

El ingreso es $R = 1$. El producto 1 deja más ganancia hoy, pero el producto 2 produce éxitos con mayor frecuencia y puede mejorar la reputación de A. La empresa valora el futuro con factor de descuento $\gamma = 0.98$.

La pregunta central es:

Idea principal. ¿Durante cuánto tiempo vale la pena sacrificar ganancia presente para mejorar la reputación y atraer demanda futura?

Todos los experimentos mantienen este problema del vendedor. Lo que cambia es la regla mediante la cual el usuario convierte la evidencia observada en una probabilidad de elegir A.

2. Creencias y demanda

2.1. La creencia básica

Sea S el número de éxitos observados y F el número de fracasos. Se parte de una distribución uniforme $\text{Beta}(1, 1)$. Después de observar (S, F) , la creencia estándar es

$$\theta \mid S, F \sim \text{Beta}(1 + S, 1 + F), \quad (1)$$

donde θ representa la calidad desconocida de A. Su media es

$$m(S, F) = \frac{1 + S}{2 + S + F}. \quad (2)$$

La notación que se usará en todo el reporte es:

Símbolo	Significado
S, F	Éxitos y fracasos observados para A.
m	Calidad media que el usuario atribuye a A.
p_0	Calidad conocida del vendedor B.
D	Probabilidad de que el usuario elija A.
V	Valor presente de las ganancias futuras de A.
$\eta, T, \varepsilon, \rho$	Parámetros de los métodos alternativos.

2.2. Thompson sampling estándar

Thompson sampling hace un sorteo $\tilde{\theta}$ de la creencia y elige A si el sorteo supera a p_0 . Por tanto,

$$D_{\text{TS}}(S, F) = \mathbb{P}(\tilde{\theta} \geq p_0), \quad \tilde{\theta} \sim \text{Beta}(1 + S, 1 + F). \quad (3)$$

No significa que el usuario crea que A tiene exactamente esa probabilidad de éxito. Significa que la demanda es la probabilidad de que una muestra de la creencia de A supere a la opción conocida.

3. Métodos comparados

3.1. Actualizaciones escaladas

Las actualizaciones escaladas multiplican cada observación por η :

$$\theta \mid S, F \sim \text{Beta}(1 + \eta S, 1 + \eta F). \quad (4)$$

- Si $\eta < 1$, cada dato pesa menos y el prior tarda más en desaparecer.
- Si $\eta > 1$, cada dato pesa más y el usuario reacciona con más fuerza.
- Si $\eta = 1$, se recupera Thompson sampling estándar.

El experimento usa $\eta \in \{0.25, 0.5, 1, 2, 4\}$.

3.2. Temperatura que preserva la media

La temperatura modifica la concentración de la creencia sin cambiar su media:

$$\theta \mid S, F \sim \text{Beta}\left(\frac{1 + S}{T}, \frac{1 + F}{T}\right). \quad (5)$$

En efecto,

$$\frac{(1 + S)/T}{(2 + S + F)/T} = \frac{1 + S}{2 + S + F} = m(S, F). \quad (6)$$

Así, T cambia la incertidumbre pero no la estimación media:

- $T < 1$: distribución más concentrada, como si hubiera más precisión.
- $T > 1$: distribución más dispersa, como si hubiera menos precisión.
- $T = 1$: Thompson sampling estándar.

El experimento usa $T \in \{0.25, 0.5, 1, 2, 4\}$.

3.3. Epsilon-greedy uniforme

Epsilon-greedy compara la media m con p_0 . Con probabilidad $1 - \varepsilon$ el usuario toma la opción con mayor media; con probabilidad ε explora uniformemente entre A y B. La demanda de A es

$$D_\varepsilon(m) = \begin{cases} 1 - \varepsilon/2, & m > p_0, \\ 1/2, & m = p_0, \\ \varepsilon/2, & m < p_0. \end{cases} \quad (7)$$

Por ejemplo, si $\varepsilon = 0.1$, la demanda puede ser 0.95, 0.50 o 0.05. Esta es exploración uniforme entre dos vendedores; no es la versión de exploración dirigida que asigna toda la exploración a A.

El experimento usa $\varepsilon \in \{0, 0.02, 0.05, 0.1, 0.2, 0.5, 1\}$.

3.4. Olvido

Para explicar el olvido conviene usar dos contadores efectivos, u para éxitos y v para fracasos. La creencia es

$$\theta \sim \text{Beta}(1 + u, 1 + v). \quad (8)$$

Cuando llega una observación nueva, una fracción ρ de la evidencia vieja se conserva:

$$\text{éxito: } (u', v') = (\rho u + 1, \rho v), \quad (9)$$

$$\text{fracaso: } (u', v') = (\rho u, \rho v + 1). \quad (10)$$

Cuanto más pequeño es ρ , más rápido se olvida. Se comparan dos relojes:

- **Olvido por observación:** si B es elegido, no cambia la memoria, $(u', v') = (u, v)$.
- **Olvido por calendario:** la memoria envejece cada periodo, aun cuando B es elegido, $(u', v') = (\rho u, \rho v)$.

La memoria efectiva está acotada aproximadamente por

$$u + v \leq \frac{1}{1 - \rho}. \quad (11)$$

Esta cota es la diferencia esencial con los métodos de conteos acumulados: el pasado nunca llega a dominar completamente a la información reciente.

4. El problema dinámico del vendedor

Sea z el estado actual de la creencia. Escribimos z^+ para el estado tras un éxito, z^- tras un fracaso y z^0 cuando A no es elegido. Si A usa el producto $j \in \{1, 2\}$, su valor condicional a recibir la interacción es

$$Q_j(z) = R - c_j + \gamma[p_j V(z^+) + (1 - p_j)V(z^-)]. \quad (12)$$

La ecuación de Bellman es

$$V(z) = D(z) \max\{Q_1(z), Q_2(z)\} + \gamma[1 - D(z)]V(z^0). \quad (13)$$

La primera parte corresponde a periodos en que A es elegido. La segunda parte corresponde a periodos sin venta para A.

La diferencia entre los dos productos se simplifica a

$$Q_2(z) - Q_1(z) = -(c_2 - c_1) + \gamma(p_2 - p_1)[V(z^+) - V(z^-)]. \quad (14)$$

Por tanto, el producto 2 es óptimo si

$$\gamma[V(z^+) - V(z^-)] > \frac{c_2 - c_1}{p_2 - p_1} = \frac{0.60}{0.45} = \frac{4}{3}. \quad (15)$$

El lado izquierdo mide cuánto vale conseguir un éxito en lugar de un fracaso. El lado derecho es el costo adicional por unidad adicional de probabilidad de éxito.

Cuando $z^0 = z$, como sucede en todos los métodos de conteos y en el olvido por observación, la ecuación (13) puede despejarse exactamente:

$$V(z) = \frac{D(z) \max\{Q_1(z), Q_2(z)\}}{1 - \gamma[1 - D(z)]}. \quad (16)$$

Para el olvido por calendario no se puede hacer este despeje porque la creencia cambia incluso cuando A no es elegido.

5. Qué experimentos se realizaron

5.1. Sensibilidad de la demanda

Para un estado con $n = S + F$ observaciones se calcula cuánto cambia la demanda si la próxima observación es un éxito en vez de un fracaso:

$$g_n = \max_{S+F=n} [D(S+1, F) - D(S, F+1)]. \quad (17)$$

Si g_n cae hacia cero, una observación adicional termina teniendo muy poco efecto sobre la demanda. Si la sensibilidad permanece grande, todavía puede haber un incentivo reputacional para usar alta calidad.

Demand sensitivity on log-log axes




Figura 1: Sensibilidad máxima de la demanda. Las reglas suaves de conteos se aproximan a la pendiente de referencia $-1/2$. Epsilon-greedy conserva un salto en el umbral y por eso no sigue la misma caída suave.

5.2. Regiones de política

Para cada estado se resuelve si el producto 1 o el producto 2 maximiza el valor. Los gráficos muestran dónde la venta reputacional supera el costo adicional de calidad.

Product-2 policy regions: standard TS and scaled updates




Figura 2: Regiones donde el producto 2 es óptimo bajo Thompson sampling y actualizaciones escaladas. El eje horizontal representa evidencia acumulada y el vertical resume la creencia media.




Figura 3: Regiones de producto 2 con epsilon-greedy uniforme. El salto de la demanda cerca de $m = p_0$ mantiene estados activos a niveles altos de evidencia para $\varepsilon < 1$.

5.3. Simulaciones largas

El perfil completo simula 1,000 trayectorias durante 5,000 periodos, desde el mismo prior y con números aleatorios comunes entre métodos. Se reportan, entre otras cantidades, demanda, ganancia, uso de producto 2 y uso tardío en los periodos 4,000 a 5,000.

Método	Demanda realizada	Uso tardío de 2 dado A	Ganancia descontada
TS estándar	0.132	0.000	27.03
Escalado, $\eta = 0.5$	0.093	0.000	25.01
Escalado, $\eta = 2$	0.218	0.000	28.24
Temperatura, $T = 0.5$	0.218	0.000	28.53
Temperatura, $T = 2$	0.093	0.000	25.32
Epsilon-greedy, $\varepsilon = 0.1$	0.922	0.334	28.77
Olvido por observación, $\rho = 0.95$	0.778	0.544	22.61
Olvido por calendario, $\rho = 0.95$	0.783	0.572	22.34

“Uso tardío de 2 dado A” es la fracción de interacciones tardías de A en las que efectivamente se empleó el producto 2. No es la fracción de todos los periodos del calendario.




Figura 4: Uso tardío del producto 2 al variar exploración (izquierda) y memoria (derecha). Son diagnósticos dentro de un horizonte finito.

5.4. Matriz dinámica para distintos valores de p_0

El segundo bloque de simulaciones cambia la calidad de la opción B:

$$p_0 \in \{0.1, 0.3, 0.5, 0.7, 0.9\}. \quad (18)$$

Para cada valor se simulan 1,000 trayectorias durante 250 periodos. Cada panel muestra promedios contemporáneos entre trayectorias, no promedios acumulados.

Como referencia se dibuja la mezcla mínima que iguala la calidad esperada de B:

$$a_{\text{mant}} = \frac{p_0 - p_1}{p_2 - p_1}, \quad (19)$$

si el resultado está entre cero y uno. Para $p_0 = 0.5$ esta mezcla es $a_{\text{mant}} = 1/3$. Es sólo un punto de comparación de calidad, no la solución del programa dinámico.

Average simulated dynamics under the optimal policy — focused learning rules at $p_0=0.5$




Figura 5: Dinámica enfocada para $p_0 = 0.5$. Se muestran market share, uso efectivo del producto 2 condicional en A, ganancia y creencia media. Las diferencias al comienzo son transiciones; no deben confundirse con los resultados tardíos de la simulación de 5,000 periodos.

6. Cómo se resolvió numéricamente

6.1. Estados discretos

Los métodos sin olvido viven en la cuadrícula triangular

$$(S, F), \quad S \geq 0, \quad F \geq 0. \quad (20)$$

El valor se calcula hacia atrás desde una diagonal exterior. El perfil completo compara diagonales exteriores 800, 1,200 y 1,600 sobre el mismo interior $S + F \leq 600$. Cuando la región activa queda demasiado cerca del borde, se usan diagonales 3,000 y 3,600 y se compara hasta $S + F \leq 2,200$.

6.2. Estados continuos de olvido

Con olvido, u y v no son enteros. Para mantener una región numérica acotada se usan las coordenadas

$$x = (1 - \rho)u, \quad y = (1 - \rho)v, \quad (21)$$

que satisfacen $x \geq 0$, $y \geq 0$ y $x + y \leq 1$. El valor se calcula en una malla triangular y se interpola linealmente entre nodos. Se comparan resoluciones 201, 401 y, para casos seleccionados, 801 o superiores.

6.3. Validaciones

Antes de cada corrida se ejecutan pruebas automáticas que verifican:

- la ecuación de Bellman y sus residuos;
- acuerdo con el solver base;
- las identidades $\eta = 1$ y $T = 1$ con Thompson sampling estándar;
- estabilidad de la política al ampliar la frontera;
- transiciones e interpolación de los modelos con olvido;
- estabilidad sobre estados visitados en las simulaciones.




Figura 6: Diagnóstico de convergencia para olvido por observación. El valor converge aproximadamente a segundo orden y los desacuerdos de política se concentran en una frontera muy delgada.

7. Lectura simple de los resultados

7.1. Métodos de conteos acumulados

Para Thompson sampling, actualizaciones escaladas y temperatura fija, la sensibilidad marginal de la demanda se reduce a medida que crece la evidencia. En la política numérica, la región de producto 2 termina después de una cantidad finita de observaciones.

Parámetro	0.25	0.5	1	2	4
Última diagonal activa, escalado η	96	210	435	885	1784
Última diagonal activa, temperatura T	1784	884	435	212	102

Estos números dependen de la calibración. Su interpretación no es que una regla sea siempre mejor, sino que cambia cuánto dura el incentivo reputacional.

7.2. Epsilon-greedy

Cuando $\varepsilon < 1$, la demanda conserva un salto alrededor de $m = p_0$. Ese salto mantiene valor reputacional incluso con mucha evidencia, y las simulaciones muestran uso recurrente del producto 2. El caso $\varepsilon = 1$ es diferente: la demanda de A es siempre $1/2$, no depende de la reputación y el producto 2 nunca se usa.

7.3. Olvido

El olvido evita que la memoria efectiva crezca sin límite. Una secuencia reciente de éxitos o fracasos puede seguir moviendo la demanda, de modo que el incentivo reputacional puede reaparecer. Las simulaciones muestran uso tardío recurrente para los parámetros estudiados.

Para olvido por observación con $\rho = 0.95$ existe además un resultado más fuerte y específico: un certificado numérico identifica una región con ventaja estricta para el producto 2 y una secuencia finita de resultados que devuelve las creencias maduras a esa región. Esto respalda uso infinito casi seguro bajo esa calibración, sujeto al alcance numérico documentado. No se debe generalizar automáticamente a todo ρ ni al reloj de calendario.




Figura 7: Dos ingredientes del certificado para olvido por observación con $\rho = 0.95$: una región con ventaja estricta y una secuencia que lleva las creencias maduras de vuelta a ella.

8. Qué no debe concluirse

- Los resultados son para $(p_1, p_2, c_1, c_2, R, \gamma) = (0.35, 0.80, 0.05, 0.65, 1, 0.98)$ y para las mallas y horizontes indicados.
- Una frecuencia tardía positiva en 5,000 periodos es evidencia de persistencia dentro de la simulación; por sí sola no prueba uso infinito.
- Una última diagonal activa numérica requiere comprobar que está lejos de la frontera artificial. El experimento hizo esa comparación, pero sigue siendo una aproximación de truncación.
- Las políticas con olvido son soluciones interpoladas de un estado continuo. Cerca de la frontera entre productos pueden existir pequeños desacuerdos entre mallas.

- Números aleatorios comunes reducen ruido al comparar métodos, pero no convierten una simulación en un teorema.
- La mayor ganancia observada en una corrida no implica que un método domine para otros parámetros, priors u horizontes.

9. Conclusión

El mensaje unificador es sencillo. El producto 2 se usa para comprar una mejor reputación futura. Si una observación adicional deja de mover la demanda, ese beneficio reputacional desaparece y el vendedor termina usando sólo el producto barato. Si la demanda conserva un salto o la memoria permanece acotada por olvido, la reputación sigue siendo sensible y la inversión en calidad puede repetirse.

En forma resumida:

Familia	Lectura principal en este experimento
TS, escalado y temperatura fija	La sensibilidad se desvanece y la región de producto 2 termina en una diagonal finita.
Epsilon-greedy, $\varepsilon < 1$	El salto de demanda sostiene uso recurrente del producto 2.
Epsilon-greedy, $\varepsilon = 1$	La demanda no depende de reputación; no hay razón para pagar por calidad.
Olvido	La memoria acotada mantiene viva la respuesta a datos recientes y se observa inversión recurrente.

El reporte resume los archivos, configuraciones y resultados generados en `Modular DP`. Las figuras conservan sus etiquetas originales en inglés para que puedan localizarse directamente en el catálogo reproducible del experimento.