Forgetting con reemplazo aleatorio

Dos pruebas de la política de intervalo

Progress notes

3 de noviembre de 2026

Esta nota explica por qué, cuando la memoria está llena, el vendedor elige el producto de mayor calidad en un solo intervalo de estados. La primera prueba sigue las ecuaciones de Bellman. La segunda usa programación lineal para demostrar que la mejor política de dos umbrales es óptima en el problema completo.

Las dos pruebas comparten un paso: demostrar que la ventaja de elegir el producto 2 no puede ser positiva en dos regiones separadas por una región donde es no positiva. La prueba por programación lineal utiliza ese paso y lo combina con un certificado de optimalidad.

1. El modelo y el resultado que queremos probar

1.1. Estado, productos y demanda

La capacidad n es un entero positivo. La memoria contiene exactamente n resultados. El estado s es el número de éxitos recordados, de modo que $s \in \{0, \dots, n\}$. El vendedor puede entregar dos productos. El producto 2 tiene mayor probabilidad de éxito y también mayor coste. Suponemos

$$0 < p_0 < 1, \qquad 0 < p_1 < p_2 < 1, \qquad 0 \le c_1 < c_2 < R, \qquad 0 < \gamma < 1. \tag{1}$$

Aquí p_0 es la calidad de la opción externa, p_i es la probabilidad de éxito del producto i, c_i es su coste, R es el ingreso por venta y γ es el factor de descuento por período calendario.

Con prior Beta$(1, 1)$ y la regla de elección del modelo, la probabilidad de comprar al vendedor en el estado s es

$$d_s = \Pr\{\text{Beta}(s+1, n-s+1) > p_0\} = \sum_{j=0}^{s} \binom{n+1}{j} p_0^j (1-p_0)^{n+1-j}. \tag{2}$$

La segunda expresión es una identidad entre la distribución Beta y la binomial. Nos permitirá estudiar cómo cambia la demanda al recordar un éxito adicional. En particular, $d_s > 0$ para todos los estados.

Después de cada compra, el resultado nuevo reemplaza una observación antigua elegida uniformemente, con independencia de si el resultado nuevo fue un éxito o un fracaso. Por ello, condicional a una compra y a usar el producto i,

Estado siguiente	Probabilidad	Qué ocurrió
$s+1$	$p_i(1 - s/n)$	Éxito nuevo; se elimina un fracaso.
$s-1$	$(1-p_i)s/n$	Fracaso nuevo; se elimina un éxito.
s	Probabilidad restante	El dato nuevo y el eliminado coinciden.

En $s = 0$ no se puede bajar y en $s = n$ no se puede subir. Si el consumidor elige la opción externa, el estado no cambia y el beneficio del período es cero.

1.2. Qué significa una política de intervalo

Una política estacionaria asigna un producto a cada estado, sin depender del período calendario. Queremos demostrar que existe una política óptima de la forma

$$\pi(s) = \begin{cases} 2, & L \le s \le U, \\ 1, & \text{en los demás estados.} \end{cases} \tag{3}$$

Es decir, al recorrer los estados de menor a mayor, la política tiene el patrón

$$\underbrace{1, \ldots, 1}_{s<L}, \qquad \underbrace{2, \ldots, 2}_{L \le s \le U}, \qquad \underbrace{1, \ldots, 1}_{s>U}.$$

Se permiten intervalos que llegan a un extremo, un único estado, todo el espacio de estados o ningún estado. Por tanto, el resultado incluye políticas con un solo umbral y políticas constantes.

Proposición 1. *Bajo los supuestos* (1)*, con prior Beta*$(1, 1)$ *y memoria llena, existe una política óptima de intervalo. Podemos elegir el producto 1 siempre que ambas acciones den el mismo valor. Si no hay empates, la política óptima estacionaria es única.*

El resultado no requiere restricciones adicionales sobre los parámetros de (1). Se refiere a memoria llena; al final de la nota explicamos por qué el llenado inicial debe tratarse por separado.

2. Primera prueba: estudiar la ventaja del producto 2

2.1. Qué comparación determina la acción

Sea V_s el beneficio descontado óptimo a partir del estado s. La ecuación de Bellman considera primero si ocurre una compra y, si ocurre, compara los dos productos. Usando las probabilidades de transición de la tabla y agrupando los términos en V_s, obtenemos

$$\begin{aligned}(1-\gamma)V_s = d_s \max_{i \in \{1,2\}} \Big\{ & R - c_i + \gamma p_i (1 - s/n)(V_{s+1} - V_s) \\ & - \gamma (1 - p_i)(s/n)(V_s - V_{s-1}) \Big\}.\end{aligned} \tag{4}$$

En los extremos omitimos el término cuyo coeficiente es cero. Esta convención se mantiene en todas las expresiones con estados vecinos.

Para comparar acciones, escribimos únicamente las dos diferencias de parámetros que aparecen una y otra vez:

$$\Delta p = p_2 - p_1, \qquad \Delta c = c_2 - c_1.$$

Si usamos V como valor de continuación, la ventaja del producto 2 frente al producto 1, condicional a una compra, es

$$G_s = -\Delta c + \gamma \Delta p \left[(1 - s/n)(V_{s+1} - V_s) + (s/n)(V_s - V_{s-1}) \right]. \tag{5}$$

El primer término es el coste adicional. El segundo es el beneficio futuro de aumentar la probabilidad de éxito. Los dos incrementos del valor aparecen porque un éxito nuevo puede elevar el estado, o evitar la caída que habría producido un fracaso.

El producto 2 es estrictamente mejor cuando $G_s > 0$. Así, basta demostrar que los estados con ventaja positiva forman un intervalo. Para un problema finito y descontado como este existe una política óptima estacionaria: podemos elegir en cada estado una acción que alcance el máximo de Bellman.

2.2. Una transformación que cancela el coste adicional

La constante

$$k = \frac{\Delta c}{\gamma \Delta p}$$

es el incremento de valor que, después de descontar y multiplicar por la mejora en la probabilidad de éxito, compensa exactamente el coste adicional. Restemos ese incremento de referencia por cada éxito recordado:

$$W_s = V_s - ks. \tag{6}$$

Por ejemplo, $V_{s+1} - V_s = (W_{s+1} - W_s) + k$. Al sustituirlo en (5), los dos pesos suman uno y el término $\gamma \Delta p\, k$ cancela Δc. Queda

$$G_s = \gamma \Delta p \left[(1 - s/n)(W_{s+1} - W_s) + (s/n)(W_s - W_{s-1}) \right]. \tag{7}$$

Ahora solo necesitamos estudiar los signos de los incrementos de W.

La misma sustitución en Bellman simplifica también el beneficio. Para cada producto se cumple

$$R - c_i + \gamma k p_i = R - c_1 + \gamma k p_1.$$

Por eso, el término que queda después de restar ks es el mismo para ambos productos. Lo llamaremos F_s:

$$F_s = d_s \left[R - c_1 + \gamma k (p_1 - s/n) \right] - (1 - \gamma) ks. \tag{8}$$

La ecuación para W queda

$$\begin{aligned} (1 - \gamma) W_s = F_s + \gamma d_s \max_{i \in \{1,2\}} \Big\{ & p_i (1 - s/n)(W_{s+1} - W_s) \\ & - (1 - p_i)(s/n)(W_s - W_{s-1}) \Big\}. \end{aligned} \tag{9}$$

Este es un cambio algebraico exacto. La cantidad F_s es una ayuda para la prueba, no un nuevo beneficio económico que se añada al modelo.

2.3. Dónde son positivos los incrementos de F

Usaremos $\Delta F_j = F_j - F_{j-1}$ para el cambio de F entre estados consecutivos. Del mismo modo, por (2),

$$\Delta d_j = d_j - d_{j-1} = \binom{n+1}{j} p_0^j (1 - p_0)^{n+1-j} > 0, \qquad j = 1, \ldots, n. \tag{10}$$

Para que las expresiones de este paso sean legibles, usaremos temporalmente una sola constante:

$$\tau = n \left[p_1 + \frac{R - c_1}{\gamma k} \right] > 0.$$

Con ella, (8) y su diferencia se escriben

$$\begin{aligned} F_s &= \frac{\gamma k}{n} d_s (\tau - s) - (1 - \gamma) ks, \\ \Delta F_j &= \frac{\gamma k}{n} \left[\Delta d_j (\tau - j) - d_{j-1} \right] - (1 - \gamma) k. \end{aligned} \tag{11}$$

Si $j \geq \tau$, todos los términos de la última expresión son no positivos y el último es estrictamente negativo. Por tanto, $\Delta F_j < 0$. Solo necesitamos estudiar los índices $j < \tau$.

La razón entre dos probabilidades binomiales consecutivas es

$$\frac{\Delta d_{j+1}}{\Delta d_j} = \frac{n+1-j}{j+1}\frac{p_0}{1-p_0}.$$

Al restar dos expresiones consecutivas de (11) y usar esa razón, obtenemos, para $j = 1, \ldots, n-1$,

$$\begin{aligned}\Delta F_{j+1} - \Delta F_j = {} & \frac{\gamma k\, \Delta d_j}{n(j+1)(1-p_0)} \\ & \times \left[(\tau - j - 1)((n+2)p_0 - j - 1) - 2(j+1)(1-p_0)\right].\end{aligned} \tag{12}$$

El factor fuera del corchete es positivo. Para entender el signo del corchete, llamemos $x = j + 1$ y observemos la expresión

$$(\tau - x)((n+2)p_0 - x) - 2(1-p_0)x. \tag{13}$$

Mientras $0 < x < \min\{\tau, (n+2)p_0\}$, los dos factores del producto son positivos y disminuyen con x. Su producto disminuye, mientras el término que restamos aumenta. La expresión empieza positiva en $x = 0$ y es negativa al llegar al menor de esos dos límites. Por eso su signo solo puede pasar una vez de positivo a negativo en ese tramo. Si $(n+2)p_0 \leq x < \tau$, el producto ya es no positivo y el término que restamos es positivo, así que la expresión sigue siendo negativa.

Esto demuestra que, entre los índices donde ΔF_j puede ser positivo, sus valores primero aumentan y después disminuyen. A partir de $j \geq \tau$, ya sabemos que son negativos. En consecuencia,

$$\{j : \Delta F_j > 0\} \quad \text{es un intervalo, posiblemente vacío.} \tag{14}$$

En palabras: al recorrer los incrementos de F, no podemos encontrar uno positivo, luego uno no positivo y después otro positivo. Esta propiedad del signo es todo lo que necesitamos; no hace falta demostrar que toda la función F sea cóncava.

2.4. La misma propiedad pasa a los incrementos del valor

En este paso fijamos *cualquier* política estacionaria π. Escribimos V^π para su valor y $W_s^\pi = V_s^\pi - ks$ para su valor transformado. No suponemos que la política sea óptima ni que tenga forma de intervalo. Esta generalidad servirá también en la prueba por programación lineal.

Para aligerar únicamente las ecuaciones de este paso, escribimos

$$\lambda_s = \gamma d_s p_{\pi(s)}(1 - s/n), \qquad \mu_s = \gamma d_s (1 - p_{\pi(s)}) s/n.$$

Son las probabilidades de subir y bajar, respectivamente, multiplicadas por el descuento. Ambas son no negativas; $\lambda_n = \mu_0 = 0$. La evaluación de la política satisface

$$(1-\gamma)W_s^\pi = F_s + \lambda_s(W_{s+1}^\pi - W_s^\pi) - \mu_s(W_s^\pi - W_{s-1}^\pi). \tag{15}$$

Llamemos $w_j = W_j^\pi - W_{j-1}^\pi$ a los incrementos que queremos estudiar. Restar la ecuación de $j-1$ de la ecuación de j da

$$\left[(1-\gamma) + \mu_j + \lambda_{j-1}\right] w_j - \mu_{j-1} w_{j-1} - \lambda_j w_{j+1} = \Delta F_j. \tag{16}$$

Cada ecuación conecta un incremento solo con sus dos vecinos. Por eso el sistema es *tridiagonal*: su matriz tiene valores distintos de cero únicamente en la diagonal y en las dos diagonales adyacentes.

Resolver este sistema no puede convertir un único intervalo positivo del lado derecho en dos intervalos positivos de la solución. Podemos verlo con la eliminación de Gauss, sin recurrir a un resultado adicional sobre matrices.

Al eliminar sucesivamente las incógnitas de izquierda a derecha, los coeficientes de la diagonal se actualizan así:

$$\begin{aligned} a_1 &= (1-\gamma) + \mu_1 + \lambda_0, \\ a_j &= (1-\gamma) + \mu_j + \lambda_{j-1} - \frac{\mu_{j-1}\lambda_{j-1}}{a_{j-1}}, \qquad j = 2, \ldots, n. \end{aligned} \tag{17}$$

Estos coeficientes son positivos. En efecto, $a_1 > \mu_1$. Si $a_{j-1} > \mu_{j-1}$, entonces

$$a_j = (1-\gamma) + \mu_j + \lambda_{j-1}\left(1 - \frac{\mu_{j-1}}{a_{j-1}}\right) > \mu_j.$$

Así, podemos hacer todas las divisiones de la eliminación.

Los lados derechos actualizados, que llamamos y_j, y la sustitución final son

$$y_1 = \Delta F_1, \qquad y_j = \Delta F_j + \frac{\mu_{j-1}}{a_{j-1}} y_{j-1}, \tag{18}$$

$$w_n = \frac{y_n}{a_n}, \qquad w_j = \frac{y_j + \lambda_j w_{j+1}}{a_j}. \tag{19}$$

La primera línea se recorre hacia la derecha y la segunda hacia la izquierda. Todos los pesos que multiplican los valores ya calculados son no negativos.

Para entender qué ocurre con los signos en (18), recorramos los índices de izquierda a derecha:

- Antes del intervalo donde $\Delta F_j > 0$, todos los valores calculados son no positivos.
- Dentro de ese intervalo, una vez que y_j se hace positivo, los siguientes siguen siendo positivos: sumamos una entrada positiva y un múltiplo no negativo de un valor positivo.
- Después del intervalo, las entradas son no positivas. Una vez que y_j se hace no positivo, ya no puede volver a ser positivo.

Por tanto, los valores positivos de y_j forman un intervalo. El mismo razonamiento, leyendo de derecha a izquierda y dividiendo por los números positivos a_j, se aplica a (19). Concluimos que

$$\{j : W_j^\pi - W_{j-1}^\pi > 0\} \quad \text{es un intervalo, posiblemente vacío.} \tag{20}$$

2.5. De los incrementos a la política óptima

Sea G_s^π la ventaja de elegir producto 2 una vez y después continuar con la política π. Se obtiene sustituyendo V^π por V en (5). Por (7), su signo es el del promedio

$$(1 - s/n)w_{s+1} + (s/n)w_s.$$

En los extremos el promedio es w_1 o w_n.

Si todos los w_j son no positivos, ninguna ventaja es positiva. En caso contrario, supongamos que los positivos están exactamente entre a y b. Para los estados $s = a, \ldots, b-1$, el promedio usa dos incrementos positivos, por lo que es positivo. Fuera de los estados $a-1, \ldots, b$, usa solo incrementos no positivos. Únicamente los dos estados $a-1$ y b pueden tener cualquiera de los dos signos. Agregar o quitar estos extremos no puede dividir el intervalo. Si $a = b$, los únicos candidatos son los dos estados consecutivos $a-1$ y a, de modo que la conclusión también vale.

Hemos demostrado algo útil por sí mismo:

Para cualquier política estacionaria fija, los estados en que es estrictamente mejor elegir producto 2 y después continuar con esa política forman un intervalo.

Para terminar la primera prueba, tomemos una política óptima estacionaria. Su valor es V. Elegir producto 2 cuando $G_s > 0$ y producto 1 cuando $G_s \leq 0$ alcanza el máximo de Bellman en cada estado, incluidos los empates. Esa elección es óptima y, por lo que acabamos de demostrar, tiene forma de intervalo. Esto prueba la Proposición 1. □

3. Segunda prueba: programación lineal y mejora de políticas

La segunda prueba organiza el mismo resultado como un problema de optimización. Primero escribimos un programa lineal que representa todas las decisiones posibles. Después mostramos que la mejor política de intervalo también resuelve ese programa completo.

Necesitaremos una conclusión de la primera prueba: para cualquier política fija, elegir en cada estado la mejor acción usando su valor de continuación produce una política de intervalo. Por tanto, esta segunda prueba comparte con la primera el argumento sobre los signos; la programación lineal permite convertirlo en un certificado de optimalidad.

3.1. Escribir Bellman como un programa lineal

Para incluir en una sola expresión tanto las compras como los períodos sin compra, escribimos $P_i(s,t)$ para la probabilidad de pasar de s a t durante un período calendario si se usa el producto i. En nuestro modelo,

$$\begin{aligned} P_i(s, s+1) &= d_s p_i (1 - s/n), \\ P_i(s, s-1) &= d_s (1 - p_i) s/n, \\ P_i(s, s) &= 1 - P_i(s, s+1) - P_i(s, s-1). \end{aligned} \tag{21}$$

En los extremos se omiten las transiciones que salen de $\{0, \ldots, n\}$. Las demás probabilidades son cero. Así, P_i ya incluye el caso en que el consumidor elige la opción externa.

El beneficio esperado de ese período es $d_s(R - c_i)$. El programa lineal de Bellman es

$$\begin{aligned} \min_{V_0,\ldots,V_n \in \mathbb{R}} \quad & \sum_{s=0}^{n} V_s \\ \text{sujeto a} \quad & V_s \geq d_s(R - c_i) + \gamma \sum_{t=0}^{n} P_i(s,t) V_t, \\ & \qquad\qquad s = 0, \ldots, n, \quad i = 1, 2. \end{aligned} \tag{22}$$

Aunque queremos maximizar los beneficios, aquí minimizamos. La razón es que cada restricción exige que V_s sea al menos tan grande como el beneficio de elegir una acción y continuar con los valores V_t. Un vector factible es, por tanto, una cota superior del valor que puede alcanzar cualquier política. Buscamos la cota más ajustada.

Para verificar esa interpretación, apliquemos una restricción a la acción que utiliza una política cualquiera. Repitiendo la desigualdad durante N períodos, V_s domina sus beneficios descontados hasta $N - 1$ más el término de continuación $\gamma^N \mathbb{E}[V_{S_N}]$, donde S_N es el estado después de N períodos. Este último término tiende a cero porque hay finitos estados y $\gamma < 1$. Por tanto, todo vector factible domina el valor de cualquier política. El valor óptimo satisface las restricciones y alcanza igualdad con la acción elegida. Es entonces la solución de (22). La formulación general se encuentra en [1].

3.2. Qué significa el dual y cómo certifica una política

El dual de (22) introduce una variable $x_{s,i}$ para cada estado y producto:

$$\begin{aligned} \min_{x_{s,i}\geq 0} \quad & \sum_{s=0}^{n}\sum_{i=1}^{2} d_s(R-c_i)x_{s,i} \\ \text{sujeto a} \quad & \sum_{i=1}^{2} x_{s,i} - \gamma\sum_{t=0}^{n}\sum_{i=1}^{2} P_i(t,s)x_{t,i} = 1, \\ & \qquad\qquad\qquad\qquad\qquad\qquad s=0,\ldots,n. \end{aligned} \tag{23}$$

Las variables $x_{s,i}$ cuentan visitas descontadas al estado s en las que la política prescribe el producto i si hay una compra. El lado derecho es uno porque en el primal sumamos el valor de todos los estados con el mismo peso. Una forma de interpretarlo es iniciar una trayectoria en cada estado y sumar sus visitas descontadas. La restricción expresa un balance: las visitas totales a s son la visita inicial más las que llegan desde el período anterior, ponderadas por γ. Sumando los balances, el número total de visitas descontadas es $(n+1)/(1-\gamma)$, de modo que es finito.

Ahora tomemos una política candidata π, por ejemplo, producto 2 entre dos umbrales y producto 1 fuera. Su valor se calcula resolviendo las ecuaciones lineales

$$V_s^{\pi} = d_s(R - c_{\pi(s)}) + \gamma\sum_{t=0}^{n} P_{\pi(s)}(s,t)V_t^{\pi}. \tag{24}$$

Por la estructura de las transiciones, cada ecuación solo involucra el estado actual y sus vecinos.

Las visitas descontadas generadas por esta política son factibles en el dual. Además, $x_{s,i} = 0$ si $i \neq \pi(s)$. Multiplicar las ecuaciones (24) por las visitas correspondientes y usar los balances del dual da

$$\sum_{s=0}^{n} V_s^{\pi} = \sum_{s=0}^{n}\sum_{i=1}^{2} d_s(R-c_i)x_{s,i}. \tag{25}$$

Así, para certificar la política solo falta comprobar que V^{π} también satisface las restricciones de la acción alternativa en (22). Si las satisface, tenemos una solución factible primal y otra dual con el mismo objetivo. La dualidad débil garantiza que ambas son óptimas. En términos de *holgura complementaria*, la política solo asigna visitas a acciones cuyas restricciones se cumplen con igualdad.

Para una candidata que usa producto 2 en $[L,U]$, esta comprobación consiste en verificar que la ventaja G_s^{π} es no negativa dentro del intervalo y no positiva fuera. Hay que verificar todos los estados, no solo los dos extremos.

3.3. Por qué algún intervalo satisface todas las restricciones

Hasta aquí sabemos cómo verificar una política candidata. Falta demostrar que podemos encontrar una candidata óptima dentro de la familia de intervalos.

Para ello usamos una *mejora de políticas*: dado el valor V^{π} de una política, elegimos en cada estado la acción con mayor beneficio actual más valor de continuación. Esta acción se llama *greedy respecto a* V^{π}. No es una decisión basada únicamente en el beneficio inmediato: incorpora la continuación de la política que acabamos de evaluar.

La mejora elige producto 2 exactamente cuando $G_s^{\pi} > 0$, y producto 1 en los demás casos. La primera prueba muestra que ese conjunto es un intervalo para *cualquier* política fija π. Sus pasos algebraicos no exigían que la política inicial fuese óptima.

Elijamos ahora la política de intervalo $\bar{\pi}$ que maximiza

$$\sum_{s=0}^{n} V_s^{\pi}$$

entre todos los intervalos, incluyendo el vacío. Esa elección existe porque hay un número finito de intervalos. Todavía no suponemos que sea la mejor entre las políticas de cualquier forma.

Supongamos que $V^{\bar{\pi}}$ viola alguna restricción del primal. Construyamos su mejora greedy, $\widehat{\pi}$. En cada estado, esta mejora puede elegir la acción que usaba $\bar{\pi}$, así que

$$d_s(R - c_{\widehat{\pi}(s)}) + \gamma \sum_{t=0}^{n} P_{\widehat{\pi}(s)}(s,t) V_t^{\bar{\pi}} \geq V_s^{\bar{\pi}}. \tag{26}$$

La desigualdad es estricta en al menos un estado, precisamente porque alguna restricción fue violada.

Para ver que la mejora también aumenta el valor total, empecemos con $V^{(0)} = V^{\bar{\pi}}$ y evaluemos repetidamente la nueva política:

$$V_s^{(\ell+1)} = d_s(R - c_{\widehat{\pi}(s)}) + \gamma \sum_{t=0}^{n} P_{\widehat{\pi}(s)}(s,t) V_t^{(\ell)}, \qquad \ell = 0, 1, \ldots.$$

Por (26), el primer paso aumenta o mantiene cada componente y aumenta estrictamente alguna. Como las probabilidades son no negativas, el siguiente paso tampoco puede reducir ninguna componente; lo mismo ocurre en todos los pasos posteriores. Esta evaluación converge a $V^{\widehat{\pi}}$: en cada iteración, el mayor error respecto a ese valor se multiplica, como máximo, por $\gamma < 1$. En consecuencia,

$$V_s^{\widehat{\pi}} \geq V_s^{\bar{\pi}} \quad \text{para todo } s, \qquad \sum_{s=0}^{n} V_s^{\widehat{\pi}} > \sum_{s=0}^{n} V_s^{\bar{\pi}}.$$

Pero la nueva política $\widehat{\pi}$ también es un intervalo, por la conclusión de la primera prueba. Esto contradice que $\bar{\pi}$ fuera el mejor intervalo.

Por tanto, $V^{\bar{\pi}}$ satisface todas las restricciones del primal. Sus visitas descontadas proporcionan una solución dual con el mismo objetivo, como en (25). La mejor política de intervalo es entonces óptima en el problema completo. □

El argumento también sugiere un procedimiento: empezar con una política cualquiera, evaluarla y mejorarla. Después de la primera mejora, la política ya es un intervalo. Las mejoras posteriores mantienen esa forma y se detienen cuando se cumplen todas las restricciones del primal. La propiedad de intervalo utilizada aquí se refiere a memoria llena; no se extiende automáticamente al llenado inicial.

4. Aplicación y alcance del resultado

Para la calibración

$$n = 20, \quad p_0 = 0.5, \quad p_1 = 0.35, \quad p_2 = 0.8,$$
$$R = 1, \quad c_1 = 0.05, \quad c_2 = 0.65, \quad \gamma = 0.98,$$

la política óptima usa producto 2 en los estados $s = 5, \ldots, 12$. Las pruebas anteriores explican por qué tiene que existir una política de intervalo; para encontrar sus extremos se evalúa la política y se verifican las desigualdades de Bellman.

En el proyecto, el archivo

`forgetting_random_replacement/code/verify_interval_theorem.py`

comprueba esta banda y las desigualdades de todas las acciones con aritmética racional exacta. Por tanto, los signos del certificado no dependen de una tolerancia numérica.

4.1. Por qué el llenado inicial es diferente

Si todavía solo se recuerdan $m < n$ observaciones, una compra lleva a la capa de memoria $m + 1$. El estado necesita ahora dos números: (m, s). La ventaja del producto 2 es

$$G_{m,s} = -\Delta c + \gamma \Delta p \, (V_{m+1,s+1} - V_{m+1,s}) \, .$$

La ecuación ya no conecta solo vecinos dentro de una capa fija, como en (16). El resultado de intervalo puede fallar.

Por ejemplo, con

$$n = 30, \quad p_0 = 0.45, \quad p_1 = 0.02, \quad p_2 = 0.15,$$
$$R = 1, \quad c_1 = 0, \quad c_2 = 0.53, \quad \gamma = 0.99985,$$

en la capa $m = 3$ las ventajas son aproximadamente

$$G_{3,0} = 0.03721, \quad G_{3,1} = -0.00979, \quad G_{3,2} = -0.02710, \quad G_{3,3} = 0.01320.$$

Se elige producto 2 en $\{0, 3\}$, que no es un intervalo. Los signos de este ejemplo también están verificados con fracciones exactas en el archivo indicado. Esta diferencia es la razón para formular ambas pruebas específicamente para memoria llena.

Referencias

[1] Lexing Ying y Yuhua Zhu (2020). *A Note on Optimization Formulations of Markov Decision Processes*. Sección 2: formulación primal y dual para problemas descontados. `https://arxiv.org/abs/2012.09417`.